

Потребительские профили муниципалитетов

Методологический отчет и результаты · 2023-2024

2016 муниципалитетов · 24 месяца · 5 типов

Цель исследования - найти сопоставимые локальные потребительские экономики и проследить изменения их состава. Сеть строится ежемесячно по сходству корзины и относительного уровня расходов.



Цвет узла соответствует типу. Показана выборка 2 000 ребер для читаемости. Расчеты используют полную сеть. Оси - главные компоненты атрибутов, зафиксированные по январю 2023.

Ключевой результат

Модель с сетевым и временным штрафами сохраняет почти тот же силуэт, что K-means (0.235 против 0.235), при более устойчивых месячных разбиениях (ARI 0.776 против 0.667). По устойчивости к изменению состава выборки K-means лучше.

1. Данные и признаки

Источник - СберИндекс, набор Data → Sense. 303 126 строк охватывают 2 190 идентификаторов за январь 2023 - декабрь 2024. Используется полная панель 2 016 МО; 174 неполных ряда исключены без заполнения пропусков.

Исходные файлы получены из публичной копии материалов хакатона 2025 года. В data/sources.json закреплены адрес первоисточника, commit зеркала и SHA-256. Официальный сервер при сборке недоступен, совпадение с текущей официальной версией не проверено.

Ключ объединения - territory_id. Справочник дает названия, регион и административные версии. Используются названия на конец 2024 года. У 183 МО есть несколько версий за анализируемый интервал. Геометрическая гармонизация границ не выполнялась.

Конструкция атрибутов

Корзина состоит из продовольствия, здоровья, маркетплейсов, общепита, транспорта и остатка «Прочие расходы». Остаток равен общему показателю минус пять категорий. Во всех используемых наблюдениях он неотрицателен.

К компонентам добавляется 0,5 единицы, затем применяется CLR: $\log(p_j)$ - среднее $\log(p)$. Отдельный признак - логарифм общего показателя за вычетом медианы по МО текущего месяца. Это относительный уровень, а не корректировка на региональные цены.

Медианы и межквартильные размахи масштабирования оцениваются только по первому полугодю 2023 года. Значения ограничиваются [-4; 4]. CLR-блок делится на $\sqrt{6}$, относительный уровень умножается на 0,5. Все параметры заданы в YAML.

Внешние показатели

Зарплата Росстата по всем отраслям, население и доступность рынков нужны для интерпретации и не участвуют в обучении. Полностью одинаковые дубликаты удалены: 5 строк зарплаты и 8 строк населения. В населении суммируются только итоговые строки мужчин и женщин, без повторного учета возрастных групп.

Панель сформирована ретроспективно. Полнота ряда проверяется на всех 24 месяцах, поэтому результаты не следует трактовать как проверку системы реального времени.

2. Сеть и временная модель

Узел - МО, ребро - сходство атрибутов. Каждый месяц выбираются 20 ближайших соседей по евклидовому расстоянию. Ребро существует при включении хотя бы в один список соседей. Матрица симметрична, петель нет.

$$w_{ij} = \exp(-d_{ij}^2 / (\sigma_i \times \sigma_j))$$

σ_i - расстояние до 20-го соседа. Локальный масштаб учитывает разную плотность наблюдений. Географическое соседство не требуется.

Основной алгоритм минимизирует сумму трех членов:

$$J = \text{компактность атрибутов} + \lambda \times \text{разрез сети} + \tau \times \text{смены меток}$$

Компактность - сумма квадратов расстояний до центров, деленная на число признаков. Разрез - сумма A_{ij} для разных меток, где $A = D^{(-1/2)} W D^{(-1/2)}$. Последний член - число отличий от меток предыдущего месяца. $\lambda = 0,5$, $\tau = 0,15$.

Инициализация K-means с 20 перезапусками. Затем узлы последовательно переносятся только при уменьшении целевой функции; центры обновляются после прохода. Пустые группы запрещены. Не более 30 проходов. Глобальный минимум не гарантируется.

Метки согласуются венгерским алгоритмом по максимальному пересечению групп. В первом месяце номера упорядочены по уровню расходов. Фиксированное K сохраняет набор типов; рождение и исчезновение групп отдельно не моделируются.

Выбор параметров и сравнение

$K = 3...7$ проверяются на январе, марте и июне 2023 года. Основная модель выбирает K по среднему рангу SW, CH, S_Dbw и Q, при среднем минимальном размере группы не менее 20. Выбрано $K = 5$. Коэффициенты штрафов зафиксированы заранее.


K-means, Ward, спектральная и основная модель сравниваются при общем K на июле 2023 - декабре 2024. Все используют одинаковые атрибуты и сеть. Это сравнение общей детализации, не оптимальных настроек каждого метода.

3. Качество и устойчивость

Метод	SW ↑	CH ↑	S_Dbw ↓	AVI ↑	AVU ↓	MQ ↑	Q ↑
graph_temporal	0.235	625.442	0.991	0.860	0.531	0.036	0.631
kmeans	0.235	656.684	0.931	0.848	0.536	0.029	0.630
spectral	0.166	494.405	0.859	0.888	0.566	0.052	0.605
ward	0.178	528.768	0.911	0.837	0.521	0.033	0.597

SW: силуэт, подвыборка 1 200 узлов с фиксированным seed. CH: отношение межгруппового и внутригруппового разброса. S_Dbw: компактность плюс плотность между центрами. Меньшее S_Dbw предпочтительно. NaN при неопределенном знаменателе сохраняется, а не заменяется нулем.


AVI оценивает удержание веса внутри группы, AVU - связанность разных групп относительно внешних связей. MQ рассчитан в варианте BasicMQ по плотностям связей. Q - отдельная модульность относительно конфигурационной модели. Формулы и соглашения полностью приведены в methodology.md.



Точки - 10 подвыборок по 80% МО; черта - средний ARI. Граф и модель строятся заново, временной штраф выключен. Это проверка устойчивости, не доверительный интервал для всех территорий.

Контроль включает 20 случайных перестановок меток с сохранением размеров групп. Вариации правила ребра и числа соседей сохранены в sensitivity.csv. При взаимном kNN с 10 соседями возникают 27 компонент, основной граф последнего месяца связан.

4. Пять типов потребительского спроса



Декабрь 2024. Доли рассчитаны как медианы по МО. Сумма медиан не обязана равняться 100%. Типы описывают потребление и не задают отраслевую классификацию производства.

T1. Базовый повседневный спрос (605 МО). Высокая доля продовольствия сочетается с низкой долей общепита и сравнительно невысокой зарплатой. Пример рядом с центром группы: Барышский (Ульяновская область).

T2. Смешанный потребительский спрос (459 МО). Промежуточный уровень расходов и разнообразная корзина без выраженного перекося в одну категорию. Пример рядом с центром группы: Рубцовск (Алтайский край).


T3. Повседневный спрос с низкой долей транспорта (517 МО). Относительно высокая доля продовольствия и маркетплейсов сочетается с низкими долями транспорта и здоровья. Пример рядом с центром группы: Козьмодемьянск (Республика Марий Эл).

T4. Высокие расходы при удалённости рынков (106 МО). Высокая зарплата и уровень расходов сочетаются с низкой доступностью рынков и меньшей долей маркетплейсов. Пример рядом с центром группы: Олекминский (Республика Саха (Якутия)).

T5. Расширенный спрос на услуги (329 МО). Выше доли общепита, здоровья и транспорта, ниже доля продовольствия. Внешние данные показывают более крупные рынки. Пример рядом с центром группы: Чертаново Центральное (Москва).

5. Внешний экономический контекст

Внешние показатели · медианы внутри типов



Годовая зарплата, население и доступность рынков не входят в атрибуты модели. Они характеризуют найденные группы после кластеризации. Сравнение использует доступные значения; пропуски не заполняются.


Показатель	Наблюдений	$\eta^2, \log(1+x)$	p, перестановки
salary	1989	0.660	0.001
population	1918	0.475	0.001
market_access	2004	0.389	0.001

Использовано 999 перестановок меток. Пространственная зависимость в тесте не учитывается, p приведены как описательная проверка. Различия не устанавливают причинную связь.

В типе 4 высокая зарплата сочетается с низкой доступностью рынков. Тип 5 также имеет высокую зарплату, но более крупные рынки и расширенный спрос на услуги. Это различие полезнее единственной шкалы «низкие - высокие расходы».

Тип 1 отличается высокой долей базовых категорий и низким уровнем сервисных расходов. Типы 2 и 3 занимают промежуточное положение; у типа 3 ниже доли транспорта и здоровья. Для выбора муниципалитета-аналога нужно дополнительно сравнивать исходные показатели и местный контекст.

6. Как меняется состав групп



Каждая горизонтальная линия верхнего рисунка - одно МО. Порядок задан типом в декабре 2024. Изменение цвета означает переход. Нижний рисунок показывает влияние временного штрафа.

7. Интерпретация изменений

Средняя доля смен типа на оценочном периоде - 9.50%, без временного штрафа - 16.56%. Более плавная динамика облегчает сравнение, но может задерживать фиксацию реальных изменений.

Между декабрем 2023 и декабрем 2024 медиана индивидуальных изменений доли маркетплейсов составляет +3,55 п.п., продовольствия -3,12 п.п. Сопоставление одинаковых месяцев уменьшает влияние сезонности, но не устраняет его полностью.

Богородский район Кировской области: тип 2 сменился типом 1, доля маркетплейсов выросла на 14,52 п.п. Ульчский район Хабаровского края: переход 2 → 1 при росте этой доли на 17,29 п.п. Катангский район Иркутской области остается в типе 4, несмотря на сильный сдвиг атрибутов. Эти примеры выбраны по величине изменения между декаблями; причины требуют отдельной проверки.

Среди 1 833 МО с единственной версией справочника средняя доля смен типа за весь период - 9,31%, для всех МО - 9,54%. Такая проверка не заменяет гармонизацию исторических границ.

Ограничения

Всего два года данных. Классификация зависит от состава признаков и полноты рядов. Цены, демография, платежное поведение и административные изменения могут влиять на показатели. Временная гладкость задана моделью, а сетевые метрики частично отражают ее собственную цель. Переход не является доказанным структурным шоком.

Воспроизведение

Python 3.12. Установить requirements.txt, затем выполнить download_data.py, run.py, analyze_results.py и build_report.py. Все настройки в configs/default.yaml. Исходные файлы уже включены и проверяются по SHA-256. Результаты, сети и исходный код находятся в репозитории.

Литература и данные

СберИндекс: Data → Sense и версионный справочник МО. Zelnik-Manor, Perona (2004), Self-Tuning Spectral Clustering. Halkidi, Vazirgiannis (2001), DOI 10.1109/ICDM.2001.989517. Biswas, Biswas (2017), DOI 10.1016/j.eswa.2016.11.011. Shalileh et al. (2026), DOI 10.1134/S1064562425700589. Mancoridis et al. (1999), Bunch. Полные ссылки: methodology.md и data/sources.json.